UNIVERSIDADE DO ESTADO DO RIO GRANDE DO NORTE

UNIDADE CURRICULAR DE EXTENSÃO

PROFESSORA GLAUCIA

LIA COMO ASSISTENTE VIRTUAL DA EDUCA

Arquitetura e funcionamento do protótipo

Natal

2026

UNIVERSIDADE DO ESTADO DO RIO GRANDE DO NORTE

UNIDADE CURRICULAR DE EXTENSÃO

PROFESSORA GLAUCIA

LIA COMO ASSISTENTE VIRTUAL DA EDUCA

Arquitetura e funcionamento do protótipo

Relatório técnico elaborado no âmbito de uma Unidade Curricular de Extensão (UCE), sob orientação da professora Glaucia, sobre o desenvolvimento de uma assistente virtual para a EdUCA no Campus de Natal da UERN.

Natal

2026

RESUMO

O atendimento pelo WhatsApp permite que o público procure informações por texto e por mensagens de voz. Este relatório descreve Lia, um protótipo de assistente virtual para a EdUCA no Campus de Natal, desenvolvido com uma extensão para navegadores baseados em Chromium e uma API em Python. O atendimento combina regras para informações previamente verificadas com recuperação de trechos de documentos oficiais e geração de respostas pelo modelo Phi-4 Mini, executado por meio do Ollama. A base reúne o edital de matrícula do semestre 2026.2 e notícias do portal da Universidade do Estado do Rio Grande do Norte. A busca utiliza BM25, enquanto os dados das turmas são organizados separadamente para evitar confusão com notícias de outros períodos. Mensagens de voz são transcritas localmente pelo Whisper, e as respostas faladas são geradas localmente pelo Kokoro, com a voz Dora. O painel web reúne as conversas e permite a continuidade do atendimento pela equipe. Os testes verificaram respostas combinadas, histórico por conversa, formato de áudio e execução do modelo na GPU. O protótipo fornece orientação, mas não realiza matrícula, não consulta vagas em tempo real e não substitui decisões da equipe. Pedidos de atendimento humano são organizados em uma fila, sem atribuição automática a um funcionário. Sua utilização institucional depende de avaliação do funcionamento na sessão do WhatsApp e de acompanhamento das informações da base.

Palavras-chave: chatbot; WhatsApp; recuperação de informações; modelo de linguagem; atendimento.

SUMÁRIO

1 INTRODUÇÃO 5

2 ARQUITETURA E TECNOLOGIAS 6

3 FUNCIONAMENTO DA EXTENSÃO 7

4 RECUPERAÇÃO DE INFORMAÇÕES 8

5 PROCESSAMENTO DE ÁUDIO 9

6 HISTÓRICO E CONTROLE DO ATENDIMENTO 10

7 VALIDAÇÃO E OPERAÇÃO 11

8 LIA: IDENTIDADE E FLUXO DE ATENDIMENTO 12

9 ESCOPO DAS RESPOSTAS 13

10 PAINEL DE ATENDIMENTO 14

11 CONSIDERAÇÕES FINAIS 20

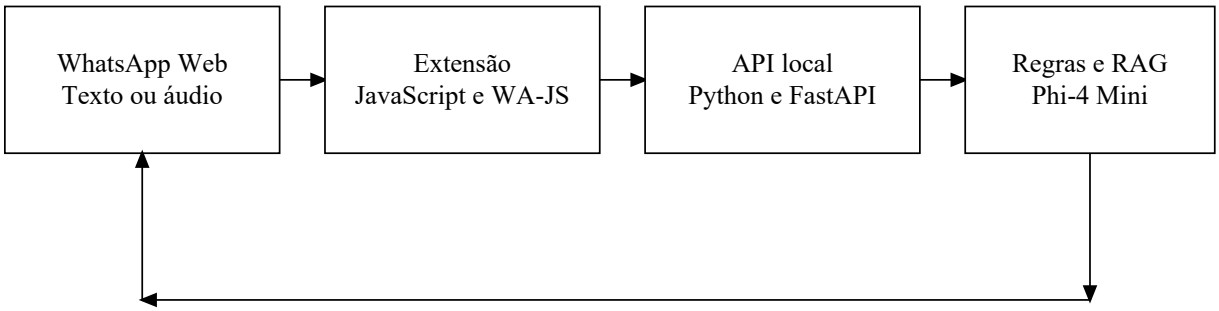
REFERÊNCIAS 21

1 INTRODUÇÃO

O Educa oferece cursos e atividades de extensão no Campus de Natal da Universidade do Estado do Rio Grande do Norte. As dúvidas do público envolvem, entre outros assuntos, faixa de idade, horário das aulas, gratuidade e matrícula. O edital 019/2026 reúne as condições previstas para o semestre 2026.2 (FUNCITERN; UERN, 2026).

O protótipo documentado neste relatório foi desenvolvido para responder a essas perguntas em uma conversa do WhatsApp Web. Sua estrutura reúne uma extensão em navegador baseado em Chromium e uma API executada no computador. A extensão recebe as mensagens e envia as respostas; a API consulta a base, aplica regras e, quando necessário, solicita uma resposta ao modelo de linguagem.

Figura 1 - Arquitetura geral do chatbot



Fonte: elaboração própria (2026).

A Figura 1 apresenta o caminho de entrada e saída das mensagens. O atendimento aceita texto e áudio, mantém um histórico curto por conversa e combina respostas controladas com recuperação de informações. O uso de áudio foi incluído para permitir que a pessoa escolha como se comunicar, sem pressupor dificuldades de leitura ou escrita.

O sistema tem função de orientação. Ele não realiza matrícula nem confirma vagas disponíveis. O modo painel acompanha novas mensagens em conversas individuais e permite que a equipe assuma o atendimento quando necessário. Grupos e a conversa da própria conta ficam excluídos. Há também um modo de teste individual para conferência do protótipo.

2 ARQUITETURA E TECNOLOGIAS

A extensão foi escrita em JavaScript, com interface em HTML e CSS e Manifest V3. Sua estrutura utiliza APIs de extensões Chromium, presentes em Chrome, Edge e Brave (MICROSOFT, s.d.). A compatibilidade esperada precisa ser conferida em cada navegador; os testes do protótipo utilizaram Brave. A API utiliza Python e FastAPI (FASTAPI, s.d.).

Quadro 1 - Componentes e tecnologias do protótipo

Componente	Tecnologia	Função
Extensão	JavaScript	Receber mensagens e controlar a comunicação com a API.
Interface	HTML e CSS	Exibir ativação, pausa e andamento do atendimento.
WhatsApp Web	WA-JS 4.6.1	Consultar mensagens e enviar texto ou áudio.
API	Python e FastAPI	Aplicar regras e organizar busca, histórico e áudio.
Modelo	Phi-4 Mini e Ollama	Gerar respostas com apoio dos trechos recuperados.
Busca	rank-bm25	Classificar os trechos por relevância lexical.
Extração	pypdf e BeautifulSoup	Ler o edital e extrair o conteúdo do portal.
Persistência	JSON e SQLite	Guardar a base, respostas e histórico curto.
Transcrição	faster-whisper small	Converter o áudio recebido em texto na CPU.
Voz	Kokoro e Dora	Gerar a resposta falada no computador.
Conversão	PyAV e Opus	Preparar áudio em OGG/Opus para o envio.

Fonte: elaboração própria (2026).

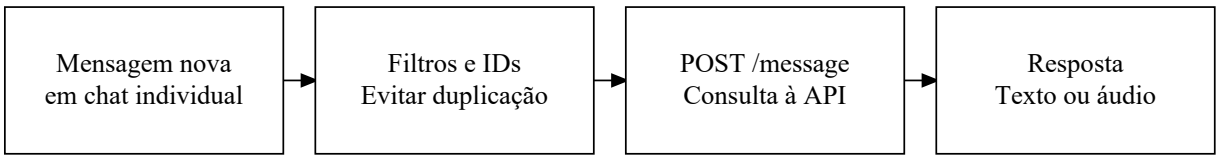
A comunicação entre extensão e API utiliza requisições HTTP com dados em JSON. JavaScript e Python executam a lógica do sistema; HTML e CSS definem a apresentação do painel. Os arquivos JSON armazenam documentos e dados de turmas, enquanto SQLite registra o histórico e as respostas em cache.

O modelo de linguagem, a busca, a transcrição e a síntese de voz são executados no computador. Kokoro utiliza a voz feminina Dora, com processamento na CPU. Essa escolha evita enviar o texto da resposta a um serviço externo de síntese e preserva os recursos da GPU para o modelo de linguagem (HEXGRAD, s.d.; THEWH1TEAGLE, s.d.).

3 FUNCIONAMENTO DA EXTENSÃO

Quando o atendimento é ativado, a extensão verifica a API e registra um ponto de partida para a leitura das conversas. No modo painel, novas mensagens de contatos individuais são identificadas sem exigir a seleção manual de cada chat. Mensagens anteriores à ativação não recebem respostas retroativas. A leitura e o envio utilizam WA-JS, biblioteca que opera sobre a sessão do WhatsApp Web (WPPCONNECT, s.d.).

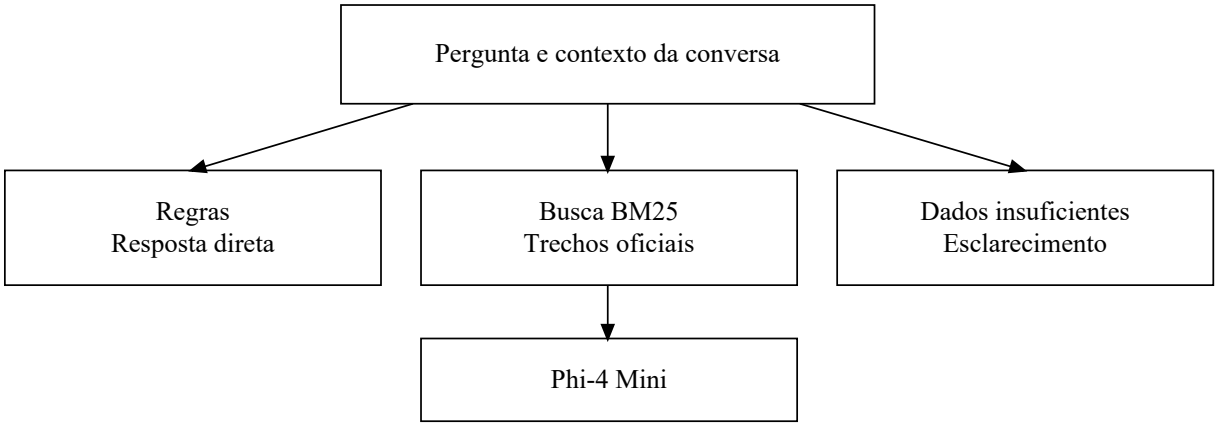
Figura 2 - Processamento de uma mensagem pela extensão



Fonte: elaboração própria (2026).

Lia é uma assistente híbrida: informações verificadas podem receber uma resposta direta por regras, enquanto outras perguntas exigem consulta aos documentos e uso da Phi. Uma mesma mensagem pode combinar assuntos, como gratuidade e faixa de idade. Nesse caso, o sistema reúne as informações necessárias para responder às partes reconhecidas da pergunta.

Figura 3 - Decisão entre regras e modelo de linguagem



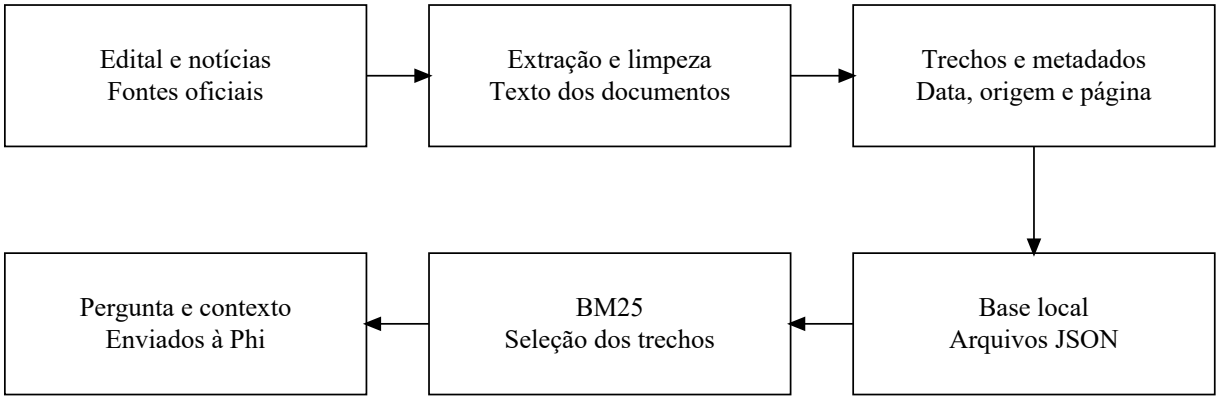
Fonte: elaboração própria (2026).

A resposta deve se limitar ao pedido atual. Uma pergunta sobre dia e horário não exige repetir idade, documentos ou disponibilidade de vagas. O histórico ajuda a identificar a turma mencionada anteriormente, mas não deve ampliar o assunto por conta própria.

4 RECUPERAÇÃO DE INFORMAÇÕES

A recuperação de informações usada no projeto é conhecida como RAG. Em vez de treinar a Phi com o edital, a API seleciona trechos relacionados à pergunta e os envia ao modelo. A busca utiliza BM25, implementação disponível na biblioteca rank-bm25 (Brown, s.d.).

Figura 4 - Preparação da base e recuperação dos trechos



Fonte: elaboração própria (2026).

A ingestão registrada em 8 de outubro de 2026 reúne 17 documentos, correspondentes a sete páginas do edital e dez notícias do portal. A divisão produziu 34 trechos. A tabela do edital foi organizada separadamente em 20 registros de turmas, adicionados à recuperação pela API. Assim, a versão documentada pesquisa 54 itens.

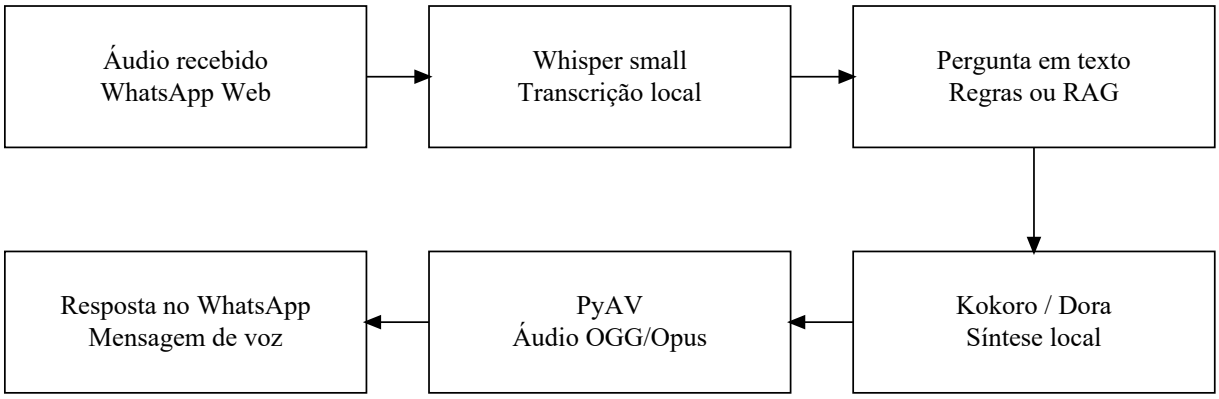
A busca é lexical, baseada nas palavras da pergunta, sem embeddings ou banco vetorial. Os trechos preservam título, origem, data e, quando disponível, página. Para horário e idade das turmas, a API prioriza os dados da tabela, evitando misturar o edital com notícias de outros períodos.

A base não cobre todo o histórico do portal e não é atualizada durante cada atendimento. Novos documentos precisam passar pela ingestão, seguida de reinício da API. O edital previa início das aulas em 3 de agosto de 2026; essa previsão não comprova o início efetivo nem a abertura de novas inscrições (FUNCITERN; UERN, 2026).

5 PROCESSAMENTO DE ÁUDIO

O processamento começa quando a extensão identifica uma mensagem de voz em uma conversa individual acompanhada. O áudio é enviado à API, que utiliza faster-whisper para obter a transcrição. Essa etapa ocorre no computador, na CPU (SYSTRAN, s.d.).

Figura 5 - Transcrição da entrada e geração da resposta falada



Fonte: elaboração própria (2026).

Depois de preparar a resposta, a API gera a fala com Kokoro e a voz Dora. O processamento é local, sem chamada ao serviço de voz da Microsoft. O fraseado conserva a pontuação da resposta, mantém saudações curtas com a frase seguinte e introduz pausas entre ideias. A velocidade pode ser ajustada sem alterar o conteúdo da orientação (HEXGRAD, s.d.; THEWH1TEAGLE, s.d.).

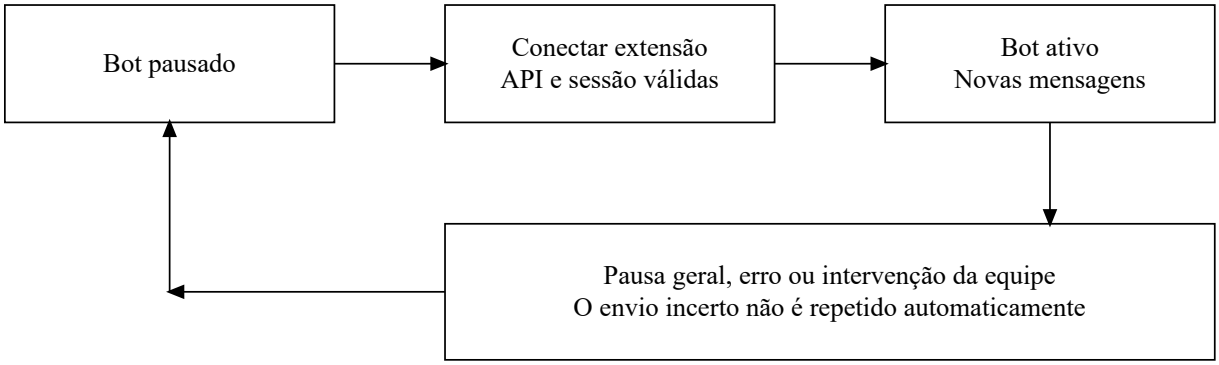
O áudio é convertido para OGG/Opus e enviado como mensagem de voz. Emojis são retirados e horários são preparados para leitura. As grafias Educa, EdUCA e EDUCA são normalizadas apenas no texto falado. Durante uma geração demorada, a extensão pode enviar um aviso pré-gravado com teclado sintético discreto, reduzido durante a fala. As respostas principais permanecem sem ruído de fundo.

O protótipo aceita áudios de até três minutos e 12 MB. Ruído, sotaque, nomes e números podem prejudicar a transcrição. Quando não entende o conteúdo, o bot pede uma repetição. Essas condições precisam ser avaliadas com mensagens reais antes de ampliar o atendimento.

6 HISTÓRICO E CONTROLE DO ATENDIMENTO

A extensão registra os identificadores das mensagens processadas em cada conversa. As saídas do próprio bot também são reconhecidas, para impedir que ele responda a si mesmo. No modo painel, os estados do atendimento separam as conversas com a Lia das que dependem da equipe. Um resultado de envio incerto não é repetido automaticamente.

Figura 6 - Ativação e pausa do atendimento



Fonte: elaboração própria (2026).

A API conserva até quatro pares de pergunta e resposta por conversa. As últimas duas trocas podem ser enviadas à Phi como contexto. Isso permite compreender perguntas como “E qual o horário?” depois de uma mensagem que identifica a turma. O histórico é separado por conversa e não é usado para treinar o modelo.

A comunicação entre extensão e API exige uma chave de acesso mantida nos arquivos de configuração. Os registros são guardados em SQLite, com retenção de vinte e quatro horas para o histórico finalizado. Perguntas e respostas permanecem legíveis no banco; o acesso a esses arquivos precisa ser controlado pela instituição.

Quando a pessoa pede um atendente, a conversa é direcionada à fila de espera da equipe. Ao assumir o chat, o atendente interrompe novas respostas da Lia naquela conversa e pode continuar por texto ou áudio. A pausa geral da extensão suspende o acompanhamento. Os estados e as ações da equipe são apresentados no capítulo sobre o painel.

A integração utiliza a sessão do WhatsApp Web e não a API oficial de atendimento. Mudanças na plataforma podem afetar o funcionamento, e existe risco de restrição da conta. O piloto precisa de acompanhamento antes de uso institucional.

7 VALIDAÇÃO E OPERAÇÃO

Os testes locais verificaram o processamento da API, a aplicação de regras e a recuperação de informações. Foram usados casos com perguntas combinadas, continuação da conversa e solicitação de apenas um dado, como dia ou horário. O Quadro 2 apresenta o alcance dessas verificações.

Quadro 2 - Verificações realizadas no protótipo

Verificação	Resultado e alcance
API e regras	Autenticação, menu da Lia, dez perguntas gerais, limites de atendimento e perguntas combinadas verificados localmente.
Histórico	Continuidade, isolamento entre conversas, limite de quatro trocas e repetição da mesma requisição.
Áudio	Síntese local Kokoro, leitura de OGG/Opus, cache de voz e transcrição verificados nos componentes locais.
WhatsApp real	Respostas em texto e comportamento da voz relatados pelo usuário; a sessão real não é inteiramente coberta pelos testes locais.

Fonte: elaboração própria (2026).

A execução do modelo de linguagem pode utilizar a GPU quando o ambiente possui memória e suporte compatíveis. Caso contrário, o processamento pode ocorrer na CPU ou ser dividido entre os dois recursos. O Ollama gerencia esse carregamento conforme a configuração disponível. A busca e as regras continuam independentes da execução da Phi; a transcrição e a síntese Kokoro utilizam a CPU no perfil documentado.

O tempo de resposta depende do tamanho da pergunta, da quantidade de mensagens agrupadas, da recuperação dos documentos e dos recursos disponíveis. O uso de GPU pode acelerar a geração de texto, mas não elimina o tempo das outras etapas. A reutilização de uma resposta falada já preparada evita uma nova síntese quando o conteúdo e o perfil de voz são iguais.

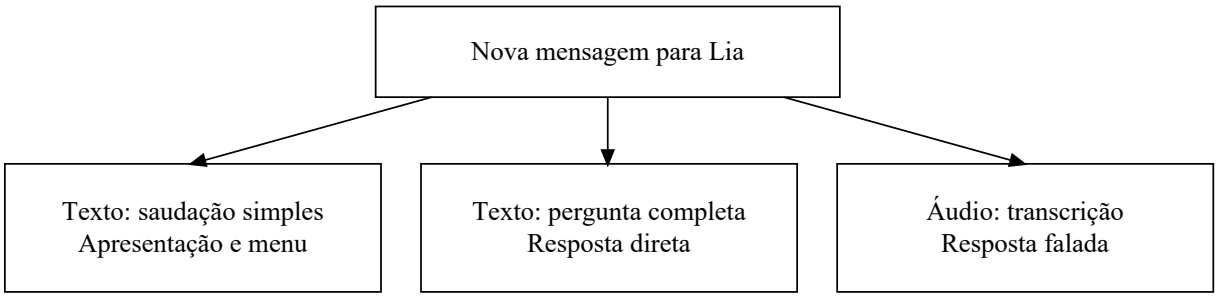
Para atender, o ambiente de processamento, o Ollama, a API e a sessão do WhatsApp Web precisam estar disponíveis. A extensão conecta as conversas ao painel, onde a equipe acompanha as filas. Pausar a extensão interrompe novas respostas automáticas; encerrar a API desliga o processamento. Parâmetros de instalação podem ser ajustados sem alterar o fluxo do atendimento.

8 LIA: IDENTIDADE E FLUXO DE ATENDIMENTO

A assistente virtual recebe o nome Lia. A escolha se deve a um nome curto, que remete a “ler” e soa muito bem em voz sintetizada. O nome identifica a assistente no painel da extensão e na apresentação inicial ao público. A voz feminina Dora é um recurso de síntese, sem imitar uma pessoa da equipe.

Uma saudação simples por texto, como “Oi” ou “Bom dia”, recebe uma apresentação e um menu numerado com dez assuntos. A pessoa pode escolher um número para obter uma resposta estática ou escrever sua pergunta livremente. O menu não é uma etapa obrigatória: perguntas completas são respondidas diretamente.

Figura 7 - Fluxo de atendimento da Lia por texto e áudio



Fonte: elaboração própria (2026).

Mensagens de áudio seguem a transcrição e recebem uma resposta falada, sem envio do menu. Se o áudio contiver apenas uma saudação, Lia se apresenta brevemente e pergunta como pode ajudar. Uma pergunta reconhecida pode ser respondida por regras; perguntas mais específicas podem utilizar a busca e o modelo de linguagem.

A redação deve ser acolhedora, simples e adequada ao pedido. Perguntas combinadas não devem perder partes da solicitação. O histórico serve para identificar uma turma já mencionada, sem repetir informações ou ampliar o assunto por conta própria.

9 ESCOPO DAS RESPOSTAS

Lia atende às dúvidas gerais descritas no Quadro 3. As respostas estáticas usam as condições verificadas no edital e indicam quando a base não permite confirmar uma informação atual. A lista histórica de cursos não equivale à confirmação de oferta ou de vagas no momento da conversa.

Quadro 3 - Assuntos atendidos pela Lia

Assunto	Orientação da resposta
Cursos e atividades	Listar os registros do semestre 2026.2 e orientar a confirmação da oferta atual.
Inscrição	Explicar o procedimento previsto e indicar que o prazo histórico já passou.
Participação	Informar o público e os critérios de idade de cada turma, sem garantir matrícula.
Gratuidade	Confirmar a gratuidade do edital; outros projetos dependem da divulgação específica.
Dias e horários	Usar a tabela conferida; solicitar a turma quando ela não estiver identificada.
Vagas	Orientar a consulta à equipe; não tratar números históricos como vagas atuais.
Local	Informar o Complexo Cultural da UERN para as atividades previstas no edital.
Documentos	Explicar a documentação prevista sem solicitar seu envio pelo chat.
Certificado	Não prometer emissão; a base não estabelece uma regra geral de certificação.
Novas turmas e projetos	Orientar o acompanhamento das divulgações oficiais, sem inventar datas.

Fonte: elaboração própria (2026).

Questões que exigem análise ou decisão da equipe, informações internas, fatos não confirmados oficialmente e situações de atendimento individualizado devem ser encaminhadas como orientação para procurar a equipe da EdUCA. Lia não decide exceções, consulta cadastros, resolve recursos ou avalia condições pessoais de saúde.

No painel, pedidos de atendente e situações que dependem de análise da equipe entram na fila de espera. A continuidade depende de uma pessoa assumir a conversa. Lia não toma decisões institucionais, não identifica um funcionário disponível e não garante um prazo de resposta humana.

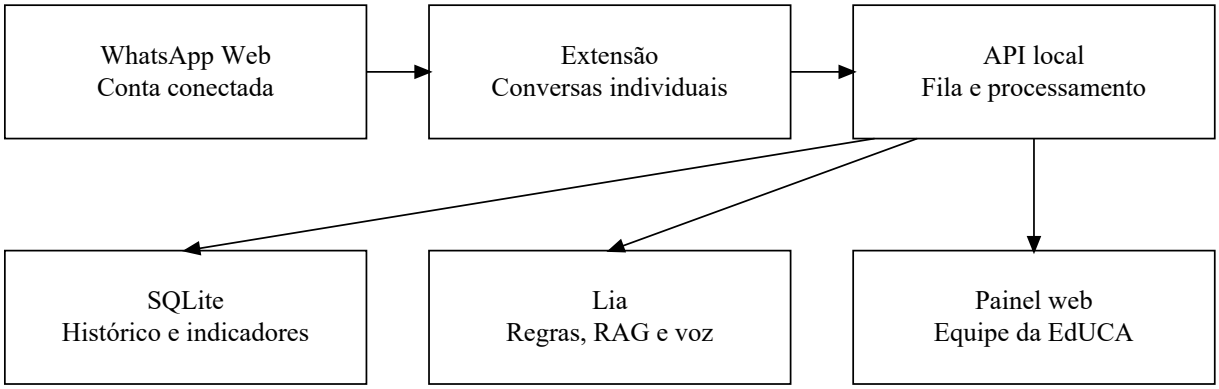
10 PAINEL DE ATENDIMENTO

10.1 Finalidade e organização

O painel amplia o atendimento da Lia ao reunir as conversas em uma interface usada pela equipe da EdUCA. Ele permite acompanhar mensagens, reconhecer pedidos que exigem intervenção humana e continuar o atendimento por texto ou áudio. Sua organização foi conferida no código-fonte do projeto (MEDEIROS, 2026).

O painel reúne as conversas recebidas pelo WhatsApp Web, mostra o histórico e permite que uma pessoa da equipe assuma o atendimento. A extensão continua responsável pela conexão com o WhatsApp; a API organiza as conversas, as respostas e a fila de envio. A equipe utiliza a interface web, enquanto a sessão do WhatsApp permanece aberta no navegador.

Figura 8 - Componentes do painel e conexão com o protótipo



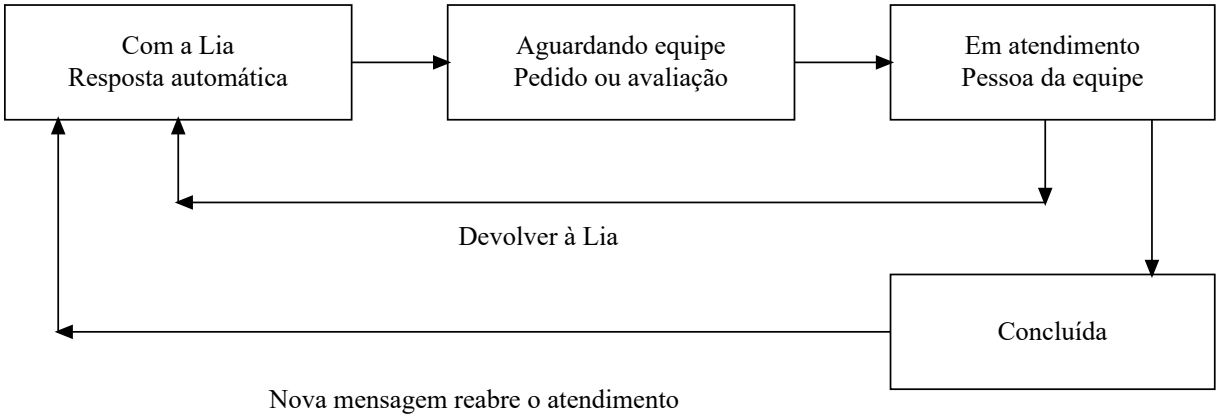
Fonte: elaboração própria (2026).

Ao clicar em “Conectar todas as conversas”, a extensão identifica mensagens novas em conversas individuais, inclusive de contatos ainda não cadastrados no painel. Grupos, comunidades, canais, status, listas de transmissão e a conversa da própria conta são excluídos. O histórico anterior à ativação, mesmo quando não lido, não dispara respostas retroativas.

10.2 CONTROLE DAS CONVERSAS E INTERVENÇÃO HUMANA

Cada conversa recebe um estado de atendimento: com a Lia, aguardando a equipe, em atendimento humano ou concluída. Um pedido de atendente, uma questão que depende de avaliação da equipe ou uma falha no processamento pode levar o chat à fila de espera. O motivo aparece no painel; a contagem da fila também é apresentada no título da aba.

Figura 9 - Estados da conversa no modo painel



Fonte: elaboração própria (2026).

Ao assumir uma conversa, a pessoa da equipe pausa a Lia naquele chat. As respostas automáticas ainda em preparação são descartadas, e as que não começaram a ser enviadas são canceladas. Um envio já iniciado pode terminar. O atendente pode escrever uma resposta ou gravar um áudio, ouvir a prévia e confirmar o envio.

A ação “Devolver à Lia” libera as próximas mensagens para atendimento automático. As perguntas recebidas durante o atendimento humano não são respondidas retroativamente. A ação “Concluir atendimento” encerra a sessão; uma mensagem posterior do contato reabre o chat com a Lia. Mensagens manuais enviadas diretamente no WhatsApp também colocam a conversa em atendimento humano.

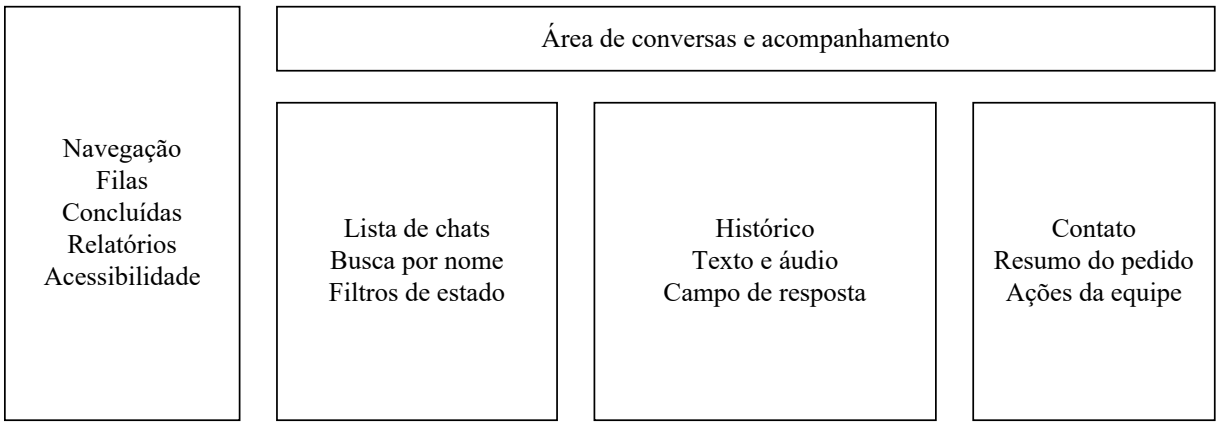
Mensagens sucessivas são reunidas após cinco segundos sem nova entrada detectada. Havendo áudio, a resposta é falada. O painel reutiliza o processamento da API; nesta implementação, a transcrição utiliza Whisper e a geração de voz utiliza Kokoro/Dora no computador. Áudios de espera previamente preparados podem ser enviados durante uma geração demorada.

A extensão reserva cada saída antes de enviá-la e informa o resultado à API. O histórico distingue mensagens na fila, em envio, enviadas, canceladas e com envio incerto. Um resultado incerto não é repetido automaticamente: a equipe deve conferir o WhatsApp antes de continuar.

10.3 INTERFACE, ACESSIBILIDADE E RESUMO DO PEDIDO

A interface utiliza HTML, CSS e JavaScript, sem dependências de uma rede de distribuição de conteúdo. A identidade visual combina tons neutros com o azul e o laranja da EdUCA. O tema escuro utiliza uma adaptação transparente da logo, com letras claras. A Figura 10 representa a distribuição dos elementos na visualização de computador.

Figura 10 - Organização da interface do painel



Fonte: elaboração própria (2026).

Quadro 4 - Recursos de interface e acessibilidade

Recurso	**Funcionamento**
Acessibilidade	Menu na barra lateral para tema escuro, contraste aumentado, tamanho do texto e redução de movimento.
Movimento reduzido	Desativa animações e respeita a preferência correspondente do dispositivo.
Teclado	Tab e Enter permitem navegação; Shift + E alterna a demonstração fora de campos de edição e diálogos.
Carregamento	Tela inicial com identidade da EdUCA e skeletons indicam a preparação e a espera pelos dados.
Demonstração	Usa conversas fictícias. Um aviso aparece por sete segundos a cada dois minutos; nenhuma mensagem é enviada.

Fonte: elaboração própria (2026).

O bloco “Lia e você, juntos” aparece apenas em conversas aguardando a equipe ou em atendimento humano. Ele reúne trechos dos pedidos recentes da pessoa, incluindo as transcrições disponíveis. Trata-se de um resumo por seleção do texto recebido, não de uma conclusão produzida pelo modelo sobre a situação do contato.

As preferências ficam salvas no navegador. No computador, listas e histórico rolam internamente; em telas menores, a interface se adapta.

10.4 RELATÓRIOS E PERSISTÊNCIA DOS DADOS

A área de relatórios permite observar a procura da comunidade em períodos de hoje, sete, trinta ou noventa dias. Os dados podem ser exportados em CSV para análise em planilhas. A demonstração identifica seus números como fictícios, mantendo-os separados dos indicadores dos atendimentos reais.

Quadro 5 - Indicadores disponíveis no painel

Indicador	Interpretação
Mensagens recebidas	Quantidade de entradas dos contatos, separadas entre texto e áudio; não inclui as respostas do bot ou da equipe.
Contatos distintos	Número de identificadores de contato diferentes no período, sem somar novamente a mesma pessoa a cada dia.
Uso de áudio	Proporção de mensagens de áudio em relação ao total de mensagens recebidas.
Assuntos e cursos	Menções reconhecidas por palavras-chave no texto e nas transcrições disponíveis.
Volume diário	Distribuição das mensagens pelos dias do período selecionado.
Encaminhamentos	Ocorrências registradas por pedido de atendente, avaliação da equipe ou falha de processamento ou integração.

Fonte: elaboração própria (2026).

Uma mensagem pode mencionar mais de um assunto ou curso. A classificação é lexical e não equivale a uma análise completa de intenção. Áudios sem transcrição disponível não contribuem para a identificação dos temas. Uma menção a um curso informa interesse, sem comprovar sua oferta, matrícula ou disponibilidade de vagas.

O painel utiliza o banco local panel.sqlite3. Mensagens finalizadas e seus áudios são limpos após vinte e quatro horas; saídas pendentes permanecem na fila. Os indicadores são conservados por até noventa dias em registros separados, sem armazenar o texto, o arquivo de áudio, o nome ou o telefone nessas tabelas. Identificadores transformados por hash permitem evitar duplicações e contar contatos distintos.

A contagem começa nos atendimentos registrados pelo painel. O histórico ainda disponível no banco durante a atualização pode ser incluído nos indicadores de demanda. Encaminhamentos ocorridos antes da implementação dos relatórios não são reconstruídos; os números não devem ser apresentados como uma série histórica completa da EdUCA.

10.5 OPERAÇÃO, VALIDAÇÃO E LIMITES

O funcionamento do painel depende da disponibilidade do ambiente de processamento e da sessão do WhatsApp Web. A extensão estabelece a conexão e disponibiliza as conversas individuais para acompanhamento. A disponibilidade da infraestrutura deve ser acompanhada pela equipe responsável.

O acesso ao painel é aberto pela extensão com um código temporário de uso único. A sessão de acesso dura oito horas e não expõe a chave da API na interface. O protótipo ainda não implementa contas individuais de atendentes nem distribuição automática por funcionário. A implantação para uso compartilhado requer definição de acesso e de responsabilidades pela instituição.

O painel e a extensão consultam atualizações periodicamente, evitando releituras desnecessárias de chats sem alterações. A suspensão da aba ou do computador pode ampliar os intervalos. O processamento de inteligência artificial é serializado, pois as conversas compartilham os recursos da máquina.

Os testes locais verificaram autenticação, descoberta de contatos novos, exclusão de grupos e da própria conta, mensagens antigas não lidas, agrupamento de texto e áudio, deduplicação e pausa. Também foram conferidos a intervenção durante a preparação de uma resposta, os estados de envio e os relatórios. A interface e o popup foram avaliados no Brave com integrações simuladas.

Essas verificações não constituem um teste completo de envio pela conta pessoal nem validam o uso institucional. A avaliação de ponta a ponta deve conferir a entrada das mensagens, a resposta da Lia e a continuidade pela equipe na sessão real. Falhas na sessão do WhatsApp podem afetar o atendimento; um chat com erro deve permanecer visível para conferência.

A integração ainda depende da extensão e do WhatsApp Web. Uma adoção futura da API oficial exigirá implementar e testar outro transporte de entrada e saída. A organização em interface, API e fila permite preservar os estados do atendimento e o processamento da Lia durante essa mudança, mas não torna a migração automática.

10.6 RISCOS DA INTEGRAÇÃO NÃO OFICIAL

A extensão automatiza a sessão do WhatsApp Web por meio de uma biblioteca de terceiros. Ela não constitui uma integração autorizada pela API oficial. O WhatsApp informa que mensagens automatizadas em desacordo com suas regras podem levar à restrição ou ao banimento da conta. Esse risco precisa ser considerado antes de usar um número institucional (WHATSAPP, s.d.).

Mudanças no WhatsApp Web, desconexão da sessão e suspensão do navegador podem interromper o atendimento. A API oficial oferece um transporte documentado de mensagens e eventos, mas exige implementação específica e cumprimento das regras da plataforma. A migração reduz a dependência da sessão do navegador; não elimina obrigações de uso ou de proteção dos dados.

10.7 Custos da API oficial

A tabela da Meta vigente desde 1º de outubro de 2026 estabelece R$ 0,035 por mensagem de serviço entregue a destinatários no Brasil, para contas faturadas em reais. Cada número recebe uma franquia de mil mensagens de serviço por mês; a cobrança começa na mensagem 1.001. A franquia não acumula para o mês seguinte. Mensagens recebidas não são cobradas (META, 2026).

Quadro 6 - Estimativa mensal de mensagens de serviço

Respostas de serviço no mês	Mensagens cobradas	Custo da Meta
1.000	0	R$ 0,00
2.000	1.000	R$ 35,00
3.000	2.000	R$ 70,00
5.000	4.000	R$ 140,00

Fonte: elaboração própria (2026).

O cálculo considera um número, apenas mensagens de serviço e a franquia mensal disponível, sem outras isenções. R$ 0,035 equivalem a 3,5 centavos. A franquia conta mensagens, não atendimentos: um áudio de espera e uma resposta final são duas saídas. Respostas livres exigem uma janela de atendimento aberta, de vinte e quatro horas após a mensagem mais recente da pessoa.

Marketing, utilidade e autenticação têm regras próprias. Provedores, infraestrutura e manutenção podem gerar custos adicionais. Os valores, consultados em outubro de 2026, devem ser reconfirmados antes da contratação.

11 CONSIDERAÇÕES FINAIS

O protótipo reúne, em uma mesma conversa, respostas por regras, consulta a documentos e comunicação por áudio. A extensão permite aproveitar a sessão do WhatsApp Web, enquanto a API concentra a base e o processamento. Essa organização facilita a revisão das respostas e a atualização das fontes sem alterar toda a interface do navegador.

As regras são úteis para informações que podem ser conferidas diretamente, como gratuidade, faixa de idade e horário de uma turma. A recuperação de trechos amplia o conjunto de perguntas que pode ser respondido, mas o modelo ainda pode acrescentar detalhes desnecessários ou interpretar uma fonte de maneira inadequada. Por isso, as respostas precisam ser limitadas ao pedido atual e avaliadas com exemplos de uso real.

A disponibilidade de vagas e as datas de novas inscrições continuam dependendo de confirmação pela equipe. Uma previsão histórica do edital não permite anunciar inscrições abertas. O painel organiza os pedidos de atendimento humano e permite a continuidade pela equipe, mas não substitui a análise institucional nem garante que uma pessoa esteja disponível no momento da solicitação.

Antes de ampliar o piloto, é necessário acompanhar a integração com o WhatsApp, revisar os resultados da transcrição e manter a base atualizada. Também devem ser avaliados o acesso aos registros e a clareza da voz. A síntese local reduz a dependência de serviços externos. Essas verificações ajudam a estabelecer o que a assistente pode responder sozinha e o que deve permanecer sob responsabilidade da equipe.

REFERÊNCIAS

BROWN, Dorian. **rank_bm25: a collection of BM25 algorithms in Python**. [S. l.], [s. d.]. Disponível em: https://github.com/dorianbrown/rank_bm25. Acesso em: 8 out. 2026.

FASTAPI. **FastAPI**. [S. l.], [s. d.]. Disponível em: https://fastapi.tiangolo.com/. Acesso em: 8 out. 2026.

FUNCITERN; UNIVERSIDADE DO ESTADO DO RIO GRANDE DO NORTE. **Edital nº 019/2026 FUNCITERN PROEX UERN: matrículas de alunos para o semestre 2026.2**. Natal, 23 jul. 2026. 7 p. Documento fornecido para a base do protótipo.

HEXGRAD. **Kokoro-82M: modelo e vozes de síntese**. [S. l.], [s. d.]. Disponível em: https://huggingface.co/hexgrad/Kokoro-82M. Acesso em: 13 out. 2026.

MEDEIROS, Juino. **Chatbot EdUCA: painel de atendimento**. Código-fonte e testes da branch feat/painel-atendimento, revisão 1e9af68. 2026. Disponível em: https://github.com/Juinuuuuw/chatbot-Educa. Consulta ao código local em: 14 out. 2026.

META. **Pricing on the WhatsApp Business Platform**. [S. l.], 2026. Disponível em: https://developers.facebook.com/documentation/business-messaging/whatsapp/pricing/. Acesso em: 14 out. 2026.

MICROSOFT. **Overview of Microsoft Edge extensions**. [S. l.], [s. d.]. Disponível em: https://learn.microsoft.com/en-us/microsoft-edge/extensions/. Acesso em: 14 out. 2026.

OLLAMA. **FAQ**. [S. l.], [s. d.]. Disponível em: https://docs.ollama.com/faq. Acesso em: 8 out. 2026.

SYSTRAN. **faster-whisper: faster Whisper transcription with CTranslate2**. [S. l.], [s. d.]. Disponível em: https://github.com/SYSTRAN/faster-whisper. Acesso em: 8 out. 2026.

THEWH1TEAGLE. **kokoro-onnx**. [S. l.], [s. d.]. Disponível em: https://github.com/thewh1teagle/kokoro-onnx. Acesso em: 13 out. 2026.

UNIVERSIDADE DO ESTADO DO RIO GRANDE DO NORTE. **Portal UERN: notícias da tag Educa**. [S. l.], [s. d.]. Disponível em: https://portal.uern.br/blog/tag/educa/. Acesso em: 8 out. 2026.

WHATSAPP. **How to use WhatsApp responsibly**. [S. l.], [s. d.]. Disponível em: https://faq.whatsapp.com/361005896189245/. Acesso em: 14 out. 2026.

WPPCONNECT. **WA-JS: documentação da versão 4.6.1**. [S. l.], [s. d.]. Disponível em: https://wppconnect.io/wa-js/. Acesso em: 8 out. 2026.